

Study Notes Series

2026 Spring

吴恩达机器学习笔记 (1)

课程：机器学习 作者：C++ 与草稿纸

本节摘要

本章介绍机器学习的基本概念，并以单变量线性回归为例，梳理从建立模型、定义代价函数到使用梯度下降训练参数的完整过程。

- **机器学习类型**：机器学习主要包括监督学习、非监督学习和强化学习；监督学习利用带标签数据学习输入到输出的映射，非监督学习则从无标签数据中发现结构与规律。
- **常见任务**：监督学习可分为预测连续值的回归问题和预测离散类别的分类问题；非监督学习的典型任务包括聚类、异常检测和降维。
- **线性回归**：使用 $f_{w,b}(x) = wx + b$ 拟合数据，并通过最小化均方误差代价函数 $J(w,b)$ 寻找合适的参数 w 和 b 。
- **梯度下降**：沿 $J(w,b)$ 梯度的反方向迭代更新参数。计算 w 、 b 的偏导数时，必须基于同一组更新前的参数，并在得到两个临时值后同时完成更新。

1 机器学习概论

机器学习的定义

塞缪尔（Arthur Samuel）对机器学习的**经典定义**是：

机器学习是使计算机在没有被明确编程的情况下，具备学习能力的研究领域。

Machine Learning is the field of study that gives computers the ability to learn without being explicitly programmed.

机器学习的类型

如今，机器学习分为三种类型

- 监督学习 (Supervised Learning)
- 非监督学习 (Unsupervised Learning)
- 强化学习 (Reinforcement Learning)

其中，监督学习 (Supervised Learning) 使用较多。

2 监督式机器学习与非监督式机器学习

2.1 监督学习

监督学习的关键特征

给算法一组“输入—正确输出”的样本，让算法学习从输入到输出的映射关系。

监督学习的分类和用途

类型	输出结果	典型例子
回归 (Regression)	连续值	预测房价、预测气温、预测成绩
分类 (Classification)	离散类别	判断垃圾邮件、判断肿瘤良恶性、识别数字

2.2 非监督学习

非监督学习的关键特征

数据集没有标签，只有特征 $x^{(i)}$ 。目标是让算法自行在数据中寻找隐藏的结构、模式或规律。

非监督学习的分类和主要特征

- 聚类 (Clustering): 用于把相同的数据点放在一起
- 异常检测 (Anomaly detection): 用来寻找特殊数据点
- 降维 (Dimensionality reduction): 用更少的变量去压缩存储数据

3 回归模型

回归问题

我们根据之前的数据预测出一个准确的输出值。

分类问题

当我们想要预测离散的输出值，例如，我们正在寻找癌症肿瘤，并想要确定肿瘤是良性的还是恶性的，这就是 0/1 离散输出的问题。

机器学习的一些符号表示

符号	表示意义
m	训练集中实例的数量
x	特征/输入变量
y	目标变量/输出变量
(x, y)	训练集中的实例
$(x^{(i)}, y^{(i)})$	第 i 个观察实例
h	学习算法的解决方案或函数

线性回归

用一条直线（或线性函数）（ $f(x) = wx + b$ ）拟合数据，从而预测连续数值。

线性回归的代价函数

$$\text{Cost function } J(w, b) = \frac{1}{2m} \sum_{i=1}^n (f_{w,b}^{(i)}(x) - y^{(i)})^2$$

$$\text{Goal : } \underset{w, b}{\text{minimize}} J(w, b)$$

4 用梯度下降法训练模型

批量梯度下降公式

$$w = w - \alpha \frac{\partial}{\partial w} J(w, b)$$

其中： α 表示学习率

参数更新的正确与错误方式

正确：同时更新参数

$$\begin{aligned}\text{tmp}_w &= w - \alpha \frac{\partial}{\partial w} J(w, b), \\ \text{tmp}_b &= b - \alpha \frac{\partial}{\partial b} J(w, b), \\ w &= \text{tmp}_w, \\ b &= \text{tmp}_b.\end{aligned}$$

两个临时值均由同一组旧参数 (w, b) 计算，之后再同时更新参数。

错误：依次更新参数

$$\begin{aligned}\text{tmp}_w &= w - \alpha \frac{\partial}{\partial w} J(w, b), \\ w &= \text{tmp}_w, \\ \text{tmp}_b &= b - \alpha \frac{\partial}{\partial b} J(w, b), \\ b &= \text{tmp}_b.\end{aligned}$$

计算 tmp_b 时， w 已是更新后的值，因此两个梯度不在同一参数点上计算。

线性回归的梯度下降

对于单变量线性回归模型

$$f_{w,b}(x^{(i)}) = wx^{(i)} + b,$$

其代价函数是关于 w 和 b 的二元函数：

$$J(w, b) = \frac{1}{2m} \sum_{i=1}^m (f_{w,b}(x^{(i)}) - y^{(i)})^2.$$

因此，可将梯度下降写成向量形式：

$$\begin{pmatrix} w \\ b \end{pmatrix} \leftarrow \begin{pmatrix} w \\ b \end{pmatrix} - \alpha \nabla J(w, b), \quad \nabla J(w, b) = \begin{pmatrix} \frac{\partial J(w, b)}{\partial w} \\ \frac{\partial J(w, b)}{\partial b} \end{pmatrix}.$$

对 $J(w, b)$ 分别求偏导，可得批量梯度下降的具体更新公式：

$$\begin{aligned}w &\leftarrow w - \alpha \frac{1}{m} \sum_{i=1}^m (f_{w,b}(x^{(i)}) - y^{(i)}) x^{(i)}, \\ b &\leftarrow b - \alpha \frac{1}{m} \sum_{i=1}^m (f_{w,b}(x^{(i)}) - y^{(i)}).\end{aligned}$$

重复上述过程直至 $J(w, b)$ 收敛。两个偏导数必须基于更新前的同一组 (w, b) 同时计算。图中的参数与这里的记号对应为 $\theta_0 = b$ 、 $\theta_1 = w$ 。