

Study Notes Series

2026 Spring

吴恩达机器学习笔记 (8)

课程：机器学习 作者：C++ 与草稿纸

本节摘要

本周回到无监督学习，介绍 K-均值聚类 and 主成分分析 (PCA)。K-均值把样本分配给若干中心，PCA 则寻找低维方向以压缩和可视化数据。两者都需要明确目标、尺度和结果解释。

1 K-均值聚类

无监督学习

无监督学习没有给定标签 y ，算法只根据输入样本 $x^{(i)}$ 寻找数据中的结构。聚类的目标是把相似样本放在同一组，把不同样本分开。

K-均值算法

给定簇数 K ，K-均值重复两个步骤：

1. **分配**：将每个样本分给距离最近的聚类中心 μ_k ；
2. **移动**：把每个中心更新为所属样本的均值。

直到样本分配不再变化或目标函数改善很小。算法输出的是簇编号和中心，不是预先存在的类别名称。

优化目标

K-均值最小化簇内平方距离：

$$J(c, \mu) = \frac{1}{m} \sum_{i=1}^m \|x^{(i)} - \mu_{c^{(i)}}\|^2,$$

其中 $c^{(i)}$ 是样本所属簇。分配步骤对固定中心最小化 J ，移动步骤对固定分配最小

化 μ ，所以每次迭代不会增加目标函数。

随机初始化与局部最优

K-均值的目标通常非凸，可能收敛到局部最优。随机选择不同初始中心并重复运行，保留目标函数最小的结果。若 K 较小，随机初始化通常更可靠；若 K 较大，应更加注意初始化质量。

选择 K

肘部法绘制不同 K 对应的代价，寻找下降速度明显变慢的位置。若没有清晰的肘部，也可以根据业务目标，例如压缩后希望保留多少类、库存需要多少组，选择具有实际意义的 K 。

2 主成分分析 PCA

2.1 动机：压缩与可视化

低维表示

若数据位于高维空间但大部分变化集中在少数方向，可以用 $k < n$ 个方向近似表示样本。PCA 选择投影后重建误差较小的方向，而不是简单删除某些坐标。

PCA 与线性回归的区别

PCA 是无监督的，不使用预测标签 y ，目标是最小化正交投影的重建误差；线性回归则选择能预测 y 的方向。不要为了压缩输入而直接运行线性回归或把 PCA 方向当作监督目标。

2.2 PCA 算法

标准步骤

对每个特征做均值归一化（必要时再除以标准差），得到 $x^{(i)}$ 。计算协方差矩阵

$$\Sigma = \frac{1}{m} X^T X.$$

对 Σ 做特征值分解或奇异值分解，选取最大的 k 个特征值对应的单位特征向量组

成矩阵 $U_{reduce} \in \mathbb{R}^{n \times k}$ ，然后投影

$$z^{(i)} = U_{reduce}^T x^{(i)}.$$

二维到一维

若二维样本主要沿一条斜线分布，PCA 会选择这条方向作为第一主成分，把点投影成一个标量 z 。这个标量保留了数据中最大的方差，适合可视化或降低后续模型的输入维度。

2.3 选择主成分数量

保留方差比例

选择最小的 k ，使投影后保留的方差比例满足

$$\frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^n \lambda_j} \geq 0.99$$

或任务需要的其他阈值。也可以直接比较重建误差。 k 不能只凭“看起来方便”决定。

重建与信息损失

低维向量可以近似重建为

$$\hat{x}^{(i)} = U_{reduce} z^{(i)}.$$

重建误差 $\|x^{(i)} - \hat{x}^{(i)}\|^2$ 越小，说明压缩丢失的信息越少。

PCA 的使用建议

- PCA 应只在训练集上拟合均值、尺度和主成分，再应用到验证集和测试集；
- 不要把 PCA 当作解决过拟合的默认方法，先用验证误差确认它确实有帮助；
- 对监督学习任务，若原始特征数量并不大，直接用正则化往往更易解释；
- 特征尺度差异很大时不做缩放，会让 PCA 主要反映量纲而非真实变化。

3 本周知识脉络

聚类与降维

K-均值通过“分配—移动”迭代最小化簇内距离；PCA 通过最大化保留方差、最小化重建误差寻找低维方向。前者输出组结构，后者输出连续坐标。二者都需要处理尺度、初始化或维度选择，并用下游目标验证实际价值。