

Study Notes Series

2026 Spring

吴恩达机器学习笔记 (4)

课程：机器学习 作者：C++ 与草稿纸

本节摘要

本周介绍神经网络的**表述 (representation)**，说明它为什么能够用较少的参数表示复杂的非线性函数，并建立从输入层到输出层的前向传播记号。这里讨论模型结构和直观例子，不展开第五周的反向传播与参数学习。

- **使用动机**：多项式特征在高维输入下会产生特征数量爆炸，神经网络可以自动组合出更有用的高阶特征；
- **模型结构**：神经网络由输入层、一个或多个隐藏层和输出层组成，每个神经元都是带激活函数的计算单元；
- **前向传播**：用 $z^{(l+1)} = \Theta^{(l)} a^{(l)}$ 和 $a^{(l+1)} = g(z^{(l+1)})$ 逐层计算预测；
- **直观理解**：单个神经元可以表示 AND、OR、NOT 等逻辑运算，多个神经元组合后可以表示 XNOR 等更复杂的函数；
- **多类分类**：输出层设置多个单元，用 one-hot 向量表示类别，并以最大输出对应的类别作为预测结果。

1 为什么需要神经网络

1.1 非线性假设与特征数量爆炸

多项式特征的局限

第三周中我们通过加入 x_1^2, x_1x_2 等多项式特征，让逻辑回归能够表示弯曲的判定边界。但当原始特征很多时，组合特征的数量会迅速增长。若有 n 个特征，仅考虑两两乘积，就有

$$\frac{n(n-1)}{2}$$

个交叉项；如果继续加入更高次项，特征数量还会进一步增加。

图像分类中的特征规模

一张 50×50 的灰度图像可以展开为 2500 个像素特征。若将每两个像素组合成一个二次特征，数量约为

$$\frac{2500^2}{2} \approx 3.1 \times 10^6.$$

直接把这些特征交给逻辑回归，会带来很高的存储和计算成本。神经网络通过多层计算学习中间表示，不必显式列出所有可能的多项式组合。

神经网络解决什么问题

神经网络仍然可以使用原始特征作为输入，但让隐藏层逐层学习新的特征表示。输出层再对这些更高级的表示进行分类或回归，因此可以用相对紧凑的参数表示复杂的非线性函数。

这也是神经网络与手工特征工程的主要区别：特征变换不完全由人预先指定，而是由网络中的权重和激活函数共同决定，并在训练过程中学习。

1.2 神经元与大脑的类比

生物学启发

神经网络的早期思想受到生物神经系统启发。生物神经元接收多个输入信号，经过处理后向其他神经元发送输出；人工神经网络则把这种过程抽象成“加权求和加激活函数”的计算单元。

这种类比主要用于帮助理解模型结构，并不意味着当前的人工神经网络完整模拟了人脑。课程中真正需要掌握的是可计算的数学模型，而不是生物学细节。

为什么近年应用重新兴起

神经网络在二十世纪八九十年代已经出现，后来因为计算量大、数据和硬件有限而较少使用。随着数据规模、并行硬件和优化方法的发展，大规模神经网络重新成为许多任务中的重要方法。**计算能力提升使更大的模型变得可训练**，但模型仍然需要合理的数据、目标函数和验证方法。

2 神经网络的模型表示

2.1 层、激活单元与权重

神经网络的层

一个前馈神经网络通常包含：

- **输入层 (Input Layer)**：接收原始特征 $x_1, \dots, x_n$ ；
- **隐藏层 (Hidden Layer)**：对上一层的输出进行变换，可以有一层或多层；
- **输出层 (Output Layer)**：产生最终预测结果。

除输出层外，常在每层加入恒为 1 的偏置单元 (bias unit)，以便模型学习平移项。每个非偏置单元称为一个**激活单元 (activation unit)**。

单个神经元的计算

对某一层的神元，先对输入做加权求和，再经过激活函数 g ：

$$z = \theta_0 a_0 + \theta_1 a_1 + \dots + \theta_n a_n, \quad a = g(z), \quad a_0 = 1.$$

本周沿用第三周的 Sigmoid 激活函数

$$g(z) = \frac{1}{1 + e^{-z}}.$$

权重决定每个输入对当前单元的影响，偏置权重决定激活曲线的位置。

2.2 神经网络的记号

层编号与激活单元

用上标表示层编号，用下标表示同一层中的单元编号：

$$a_i^{(j)} = \text{第 } j \text{ 层的第 } i \text{ 个激活单元.}$$

输入层的激活可以记作

$$a^{(1)} = \mathbf{x},$$

并令 $a_0^{(j)} = 1$ 表示第 j 层的偏置单元。连接第 j 层和第 $j+1$ 层的权重矩阵记作 $\Theta^{(j)}$ 。

权重矩阵的尺寸

若第 j 层有 s_j 个非偏置单元，第 $j+1$ 层有 s_{j+1} 个非偏置单元，则

$$\Theta^{(j)} \in \mathbb{R}^{s_{j+1} \times (s_j + 1)}.$$

行数对应下一层的神经元个数，列数对应当前层的神经元个数加一个偏置单元。矩阵中的元素 $\Theta_{ik}^{(j)}$ 表示从第 j 层的第 k 个单元到第 $j+1$ 层第 i 个单元的权重。

三层网络的结构

设输入层有 3 个特征，隐藏层有 3 个单元，输出层有 1 个单元，则从输入层到隐藏层的权重矩阵尺寸为

$$\Theta^{(1)} \in \mathbb{R}^{3 \times 4},$$

因为输入层包含 3 个特征和 1 个偏置单元；从隐藏层到输出层的矩阵尺寸为

$$\Theta^{(2)} \in \mathbb{R}^{1 \times 4}.$$

这里的“三层”通常指输入层、隐藏层和输出层，不把偏置单元另算为一层。

3 前向传播与向量化计算

3.1 逐层前向传播

前向传播

从输入层开始，按照网络连接方向逐层计算输出的过程称为**前向传播**（**Forward Propagation**）。对从第 j 层到第 $j+1$ 层的连接，先计算

$$\mathbf{z}^{(j+1)} = \Theta^{(j)} \mathbf{a}^{(j)},$$

再逐元素应用激活函数：

$$\mathbf{a}^{(j+1)} = g(\mathbf{z}^{(j+1)}).$$

如果第 $j+1$ 层不是输出层，还要在激活向量前面补上偏置单元 $a_0^{(j+1)} = 1$ 。

两层网络的完整计算

对一个输入样本 $\mathbf{x}$ ，设 $\mathbf{a}^{(1)} = \mathbf{x}$ ，则两层参数的前向传播为

$$\begin{aligned} \mathbf{z}^{(2)} &= \Theta^{(1)} \mathbf{a}^{(1)}, \\ \mathbf{a}^{(2)} &= g(\mathbf{z}^{(2)}), \quad a_0^{(2)} = 1, \\ \mathbf{z}^{(3)} &= \Theta^{(2)} \mathbf{a}^{(2)}, \\ h_{\Theta}(\mathbf{x}) &= a^{(3)} = g(\mathbf{z}^{(3)}). \end{aligned}$$

其中 h_{Θ} 表示由全部权重矩阵 $\Theta^{(1)}, \Theta^{(2)}, \dots$ 决定的神经网络假设函数。

神经网络像多层逻辑回归

如果暂时遮住输入层，只观察隐藏层到输出层，那么输出层的计算形式就是一个逻辑回归：

$$h_{\Theta}(\mathbf{x}) = g\left(\Theta_0^{(2)} a_0^{(2)} + \Theta_1^{(2)} a_1^{(2)} + \dots\right).$$

区别在于，逻辑回归直接使用原始特征 x_i ，神经网络使用隐藏层产生的 $a_i^{(2)}$ 。这些中间激活可以看作由网络自动构造的更高级特征。

3.2 训练集上的矩阵化

按列组织样本

前面的推导针对一个样本。若要同时处理 m 个样本，可以把每个样本放在矩阵的一列：

$$X^T = \begin{bmatrix} \mathbf{x}^{(1)} & \mathbf{x}^{(2)} & \dots & \mathbf{x}^{(m)} \end{bmatrix}.$$

于是隐藏层的计算可写为

$$Z^{(2)} = \Theta^{(1)} X^T, \quad A^{(2)} = g(Z^{(2)}),$$

再给 $A^{(2)}$ 添加一行偏置单元后，继续计算下一层。矩阵化能够一次处理全部样本，并充分利用数值库中的矩阵运算。

维度与偏置单元

- 忘记给隐藏层激活补 $a_0 = 1$ ，会导致下一层矩阵乘法的列数不匹配；
- 把样本按行和按列的约定混用。当前公式把单个样本作为列向量，因此整个训练集使用 X^T ；
- 把 $\Theta^{(j)}$ 的行列含义写反。它的行数是下一层单元数，列数是当前层单元数加

偏置；

- 对矩阵直接套用激活函数时没有说明是逐元素计算。这里的 g 作用于每个 z 的元素。

4 神经网络学习出的特征

4.1 从原始特征到高级特征

自动学习特征

在逻辑回归中，模型主要依赖输入层的原始特征；即使加入多项式项，特征变换也通常需要人工决定。神经网络的隐藏层将上一层的特征重新组合，输出新的激活值，下一层再基于这些激活继续组合。

因此，深层网络可以形成从边缘、纹理到局部结构等逐步抽象的表示。这里的“高级”是相对于网络输入而言，并不表示每个单元都具有独立、明确的人类语义。

为什么隐藏层有用

隐藏层把一个复杂问题拆成多个较简单的子问题：每个单元先学习一个局部判别模式，后续单元再组合这些模式。多层组合带来的表示能力，通常比一次性手工枚举所有多项式特征更灵活，也更适合图像等高维输入。

4.2 用神经元表示逻辑运算

AND 运算

令 $x_1, x_2 \in \{0, 1\}$ ，取一个带偏置的 Sigmoid 神经元：

$$h(x) = g(-30 + 20x_1 + 20x_2).$$

当且仅当 $x_1 = x_2 = 1$ 时，线性组合为正且足够大，输出接近 1；其他输入下输出接近 0。因此它近似实现

$$h(x) \approx x_1 \text{ AND } x_2.$$

OR 与 NOT 运算

对于 OR，可以改用

$$h(x) = g(-10 + 20x_1 + 20x_2),$$

只要至少一个输入为 1，输出就接近 1。对于单输入 NOT，可以使用

$$h(x) = g(10 - 20x_1),$$

输入 0 时输出接近 1，输入 1 时输出接近 0。

这些权重只是说明可行的构造，并不是训练后唯一的参数组合。

4.3 组合神经元实现 XNOR

XNOR 的逻辑分解

XNOR 在两个输入相同（都为 0 或都为 1）时输出 1，可以分解为

$$\text{XNOR}(x_1, x_2) = (x_1 \text{ AND } x_2) \text{ OR } ((\text{NOT } x_1) \text{ AND } (\text{NOT } x_2)).$$

这说明非线性分类边界可以由多个简单的神经元组合得到，而不必由单个线性分类器直接完成。

一组可行的 XNOR 网络

隐藏层可以构造两个单元：

$$a_1 = g(-30 + 20x_1 + 20x_2),$$

$$a_2 = g(30 - 20x_1 - 20x_2).$$

其中 a_1 近似 AND， a_2 近似 $(\text{NOT } x_1) \text{ AND } (\text{NOT } x_2)$ 。输出层使用 OR 单元：

$$h_{\Theta}(x) = g(-10 + 20a_1 + 20a_2).$$

于是 (0, 0) 和 (1, 1) 的输出接近 1，(0, 1) 和 (1, 0) 的输出接近 0。

逻辑运算例子的边界

- 这些例子使用人为指定的权重来解释表达能力，不等于已经完成了参数学习；
- Sigmoid 输出是接近 0 或 1 的概率，不是数学上完全等于布尔值；
- XNOR 需要组合多个单元，单个线性判定边界无法直接把两个对角区域与另外两个区域分开。

5 神经网络的多类分类

多输出单元

当类别数为 K 时，可以让输出层包含 K 个单元。对于样本 x ，输出向量可写成

$$\mathbf{a}^{(L)} = \begin{bmatrix} a_1^{(L)} & a_2^{(L)} & \cdots & a_K^{(L)} \end{bmatrix}^T.$$

标签使用 one-hot 表示：属于第 k 类时，目标向量第 k 个位置为 1，其余位置为 0。

从输出向量得到类别

在本周课程的表述中，预测类别取输出层最大激活值对应的下标：

$$\hat{y} = \arg \max_{k \in \{1, \dots, K\}} a_k^{(L)}.$$

例如，输出为 $[0.08, 0.11, 0.73, 0.08]^T$ 时，预测为第 3 类。对于现代多类分类，常用 Softmax 将输出解释为归一化概率；其具体代价函数和梯度将在后续内容中单独讨论。

识别行人、汽车、摩托车和卡车

若任务有四个类别，输出层设置四个单元，目标标签可以写为

$$\begin{aligned} \text{行人} &= [1, 0, 0, 0]^T, & \text{汽车} &= [0, 1, 0, 0]^T, \\ \text{摩托车} &= [0, 0, 1, 0]^T, & \text{卡车} &= [0, 0, 0, 1]^T. \end{aligned}$$

输入层接收图像像素或其他特征，中间层逐步提取表示，输出层给出四个类别的响应。

6 本周知识脉络

从非线性表示到多类输出

第四周的核心流程可以概括为：

1. 高维多项式特征会导致组合数量爆炸，单个逻辑回归模型难以有效处理；
2. 神经网络用带激活函数的神经元和隐藏层自动构造中间特征，并用权重矩阵记录层间连接；
3. 前向传播逐层计算 z 和 a ，向量化时要保持矩阵维度和偏置单元一致；
4. 简单神经元组合可表示复杂的非线性函数，多类任务用多输出单元和 one-hot 标签表达；下一周学习如何用反向传播学习这些权重。