

Study Notes Series

2026 Spring

吴恩达机器学习笔记 (9)

课程：机器学习 作者：C++ 与草稿纸

本节摘要

本周介绍异常检测和推荐系统。异常检测用正常样本建立概率模型，再根据概率密度识别异常；推荐系统则从用户—物品评分中学习用户偏好和物品特征，并用协同过滤与低秩分解产生推荐。

1 异常检测

1.1 问题动机

异常检测设定

训练集通常主要由正常样本组成，目标是发现概率很低的样本，例如服务器故障、欺诈交易或传感器异常。为每个特征建立概率密度 $p(x_j)$ ，组合得到

$$p(x) = \prod_{j=1}^n p(x_j).$$

若 $p(x) < \varepsilon$ ，就把样本标为异常。

1.2 高斯分布模型

单变量高斯分布

对特征 x_j 估计均值和方差：

$$\mu_j = \frac{1}{m} \sum_{i=1}^m x_j^{(i)}, \quad \sigma_j^2 = \frac{1}{m} \sum_{i=1}^m (x_j^{(i)} - \mu_j)^2.$$

高斯密度为

$$p(x_j; \mu_j, \sigma_j^2) = \frac{1}{\sqrt{2\pi}\sigma_j} \exp\left(-\frac{(x_j - \mu_j)^2}{2\sigma_j^2}\right).$$

开发与评价

用正常训练样本估计参数，在交叉验证集中混入已知正常和异常样本，选择阈值 ϵ ，再在测试集上报告查准率、查全率或 F_1 。不能只在正常训练集上选择阈值，因为那样无法衡量真正的异常识别能力。

异常检测与监督学习

异常检测适合异常类别很少、未来异常类型未知的场景；监督学习适合正负样本都较多且未来错误类型与历史相似的场景。若已有大量标注异常样本，直接使用分类器通常更有效。

1.3 选择特征与多元高斯

构造更有辨识力的特征

若两个特征单独看都近似正常，但它们的组合关系异常，可以增加比值、乘积或差值等特征。特征工程的目标是让异常样本的概率密度明显低于正常样本。

多元高斯分布

当特征相关性很强时，可以直接用协方差矩阵 Σ 建立多元高斯模型：

$$p(x) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu)\right).$$

它可以学习倾斜的等密度椭圆，但需要更多样本，并要求协方差矩阵可逆或使用稳定的数值处理。

2 推荐系统

2.1 问题形式化

评分矩阵

设 n_u 个用户、 n_m 个物品， $r(i, j) = 1$ 表示用户 j 给物品 i 评分， $y^{(i,j)}$ 为评分值。记用户是否评价过物品的指示量为 $r(i, j)$ ，目标是预测未评分项目的偏好。

2.2 基于内容的推荐

用户和物品特征

如果每个物品有特征向量 $x^{(i)}$ ，可以为用户 j 学习参数 $\theta^{(j)}$ ，预测

$$\hat{y}^{(i,j)} = (\theta^{(j)})^T x^{(i)}.$$

这与多个用户各自训练线性回归相似，但需要为用户学习偏好参数。

2.3 协同过滤

同时学习两类参数

当物品特征未知时，协同过滤同时学习用户参数 $\theta^{(j)}$ 和物品特征 $x^{(i)}$ ：

$$\min_{x, \theta} \frac{1}{2} \sum_{(i,j): r(i,j)=1} ((\theta^{(j)})^T x^{(i)} - y^{(i,j)})^2$$

加上对两类参数的正则化。用户评分越相似，算法越可能学到相近的用户偏好或物品表示。

协同过滤的梯度

对用户参数和物品特征分别求导即可用梯度下降更新：

$$\theta^{(j)} \leftarrow \theta^{(j)} - \alpha \sum_{i:r(i,j)=1} ((\theta^{(j)})^T x^{(i)} - y^{(i,j)}) x^{(i)},$$

$$x^{(i)} \leftarrow x^{(i)} - \alpha \sum_{j:r(i,j)=1} ((\theta^{(j)})^T x^{(i)} - y^{(i,j)}) \theta^{(j)}.$$

2.4 低秩矩阵分解与均值归一化

向量化预测

把物品特征组成矩阵 X 、用户参数组成矩阵 Θ ，评分预测矩阵可写成

$$X\Theta^T.$$

这是一种低秩近似：用较短的隐向量表示大量用户—物品关系。

均值归一化

对每个物品先计算已知评分的均值 μ_i ，训练残差

$$y^{(i,j)} \leftarrow y^{(i,j)} - \mu_i,$$

预测后再加回 μ_i 。这样可以使初始预测从“该物品的平均受欢迎程度”开始，而不是全部从零开始。

推荐系统的注意事项

- 只在已评分条目上计算代价，不要把未知评分当成 0；
- 推荐系统中的隐特征通常没有固定语义，不应过度解释单个维度；
- 评价指标应模拟真实推荐场景，不能只比较训练集重构误差；
- 新用户或新物品缺少历史数据时会遇到冷启动问题，需要额外特征或交互设计。

3 本周知识脉络

概率模型与隐变量表示

异常检测学习“正常数据长什么样”，用低概率阈值发现异常；推荐系统学习“用户和物品如何匹配”，用协同过滤和低秩隐向量预测偏好。两者都需要合理的验证集、稳定的特征表示和面向实际应用的评价指标。