

Study Notes Series

2026 Spring

吴恩达机器学习笔记 (2)

课程：机器学习 作者：C++ 和草稿纸

本节摘要

本节介绍多变量线性回归的向量化表示、梯度下降与特征缩放，并总结收敛诊断、特征工程和多项式回归。

1 多变量线性回归

1.1 多维特征

多维特征的符号表示

当一个训练样本包含多个输入变量时，这些输入变量称为**特征 (features)**。设每个样本共有 n 个特征，则第 i 个训练样本可写成一个 n 维列向量：

$$\mathbf{x}^{(i)} = \begin{bmatrix} x_1^{(i)} & x_2^{(i)} & \cdots & x_n^{(i)} \end{bmatrix}^T.$$

其中， $x_j^{(i)}$ 表示第 i 个训练样本的第 j 个特征。例如，若 $\mathbf{x}^{(2)} = [1416, 3, 2, 40]^T$ ，则 $x_2^{(2)} = 3$ ， $x_3^{(2)} = 2$ 。

具有 n 个特征的线性回归假设函数为

$$h_{\theta}(\mathbf{x}) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x_n.$$

令 $x_0 = 1$ ，并记 $\mathbf{x} = [x_0, x_1, \dots, x_n]^T$ 、 $\boldsymbol{\theta} = [\theta_0, \theta_1, \dots, \theta_n]^T$ ，则可将假设函数简写为

$$h_{\theta}(\mathbf{x}) = \boldsymbol{\theta}^T \mathbf{x}.$$

此时每个训练样本和参数向量都是 $(n+1)$ 维向量；若共有 m 个训练样本，则特征矩阵 X 的维度为 $m \times (n+1)$ 。

向量化的好处

对于含有多个特征的模型，若逐项计算预测值，需要依次完成求和：

$$h_{\theta}(\mathbf{x}) = \sum_{j=0}^n \theta_j x_j.$$

使用向量化后，同一计算可直接写成点积：

$$h_{\theta}(\mathbf{x}) = \boldsymbol{\theta}^T \mathbf{x}.$$

向量化主要有以下好处：

- **代码更简洁**：无需显式编写循环，模型表达式更接近数学公式，也更不容易出现索引错误。
- **计算速度更快**：NumPy 等数值计算库会使用经过优化的底层实现，比在高级语言中逐项运算更高效。
- **能够并行计算**：点积和矩阵运算可以利用 CPU 的向量指令或 GPU 的并行能力，同时处理多个元素。

当 m 个训练样本组成特征矩阵 X 时，还可以一次得到全部预测结果：

$$\hat{\mathbf{y}} = X\boldsymbol{\theta}.$$

因此，随着特征数或训练样本数增加，向量化通常能带来更明显的效率优势。

1.2 多变量梯度下降

多变量线性回归的代价函数

多变量线性回归与单变量线性回归使用相同的平方误差代价函数。对于 m 个训练样本，模型预测和代价函数分别为

$$h_{\theta}(\mathbf{x}^{(i)}) = \boldsymbol{\theta}^T \mathbf{x}^{(i)},$$

$$J(\boldsymbol{\theta}) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(\mathbf{x}^{(i)}) - y^{(i)})^2.$$

训练的目标是找到一组参数 $\boldsymbol{\theta}$ ，使 $J(\boldsymbol{\theta})$ 尽可能小。

多变量的批量梯度下降

对每个参数 θ_j ，梯度下降的更新规则为

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\boldsymbol{\theta}) = \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\boldsymbol{\theta}}(\mathbf{x}^{(i)}) - y^{(i)}) x_j^{(i)}, \quad j = 0, 1, \dots, n.$$

其中， α 是学习率。由于 $x_0^{(i)} = 1$ ，同一个公式也适用于偏置参数 θ_0 。

一次完整迭代可概括为：

1. 使用当前参数计算所有训练样本的预测值与误差；
2. 根据全部 m 个训练样本计算每个参数的梯度；
3. 使用更新前的同一组参数，**同时更新** $\theta_0, \theta_1, \dots, \theta_n$ ；
4. 重复以上过程，直到代价函数收敛。

每次更新都使用整个训练集，因此这种方法称为**批量梯度下降（Batch Gradient Descent）**。

向量化更新

令 $\mathbf{y} = [y^{(1)}, y^{(2)}, \dots, y^{(m)}]^T$ ，则全部样本的梯度和参数更新可以写成

$$\nabla J(\boldsymbol{\theta}) = \frac{1}{m} X^T (X\boldsymbol{\theta} - \mathbf{y}), \quad \boldsymbol{\theta} := \boldsymbol{\theta} - \alpha \nabla J(\boldsymbol{\theta}).$$

该形式一次计算所有参数的梯度，代码更简洁，也能利用数值计算库的矩阵运算加速。

1.3 梯度下降法的一些实践

1.3.1 特征缩放

为什么需要特征缩放

当不同特征的取值范围相差很大时，代价函数的等高线会变得狭长。梯度下降可能在较窄的方向上来回震荡，需要许多次迭代才能到达最小值。

特征缩放（Feature Scaling） 将各个特征调整到相近的数值范围，使代价函数的等高线更接近圆形。这样梯度下降可以更直接地朝最小值移动，通常能够使用更合适的学习率并更快收敛。缩放后的特征不必严格落在同一区间，重点是避免不同特征之间存在悬殊的数量级差异。

均值归一化 (Mean Normalization)

对第 j 个特征，记训练集中的均值为 μ_j ，最大值和最小值分别为 $x_{j,\max}$ 与 $x_{j,\min}$ 。均值归一化定义为

$$x_j \leftarrow \frac{x_j - \mu_j}{x_{j,\max} - x_{j,\min}}.$$

减去均值会使特征以 0 为中心，再除以取值范围则缩小其尺度。处理后的数值通常位于 $[-1, 1]$ 附近。

Z-score 标准化 (Z-score Normalization)

先使用训练集计算第 j 个特征的均值和标准差：

$$\mu_j = \frac{1}{m} \sum_{i=1}^m x_j^{(i)}, \quad \sigma_j = \sqrt{\frac{1}{m} \sum_{i=1}^m (x_j^{(i)} - \mu_j)^2}.$$

然后进行 Z-score 标准化：

$$x_j \leftarrow \frac{x_j - \mu_j}{\sigma_j}.$$

标准化后的特征均值为 0、标准差为 1。它不保证所有数据都位于 $[-1, 1]$ 内，但通常能让不同特征具有相近的尺度。

使用特征缩放时的注意事项

- 均值、最大值、最小值和标准差只能根据**训练集**计算；验证集、测试集及新输入必须复用同一组统计量，以避免数据泄漏。
- 偏置特征 $x_0 = 1$ 不需要缩放。若某个特征的取值范围或标准差为 0，说明它在训练集中是常数，应移除该特征或单独处理。
- Mean normalization 和 Z-score normalization 都能用于特征缩放。选择其中一种并在所有数据上保持一致即可。

1.3.2 检查梯度下降是否收敛

通过学习曲线判断收敛

在每次迭代后记录当前代价 $J^{(t)} = J(\theta^{(t)})$ ，并绘制横轴为迭代次数 t 、纵轴为 $J^{(t)}$ 的**学习曲线 (Learning Curve)**。

若梯度下降实现正确且学习率合适， $J^{(t)}$ 应当在每次迭代后下降。曲线逐渐变平且相邻代价变化很小时，算法可能已接近最小值。所需迭代次数因问题而异，不能只靠预设次数判断收敛。

自动收敛测试

设第 t 次迭代带来的代价下降量为

$$\Delta J^{(t)} = J^{(t-1)} - J^{(t)}.$$

选取一个很小的阈值 $\varepsilon > 0$ 。当

$$0 \leq \Delta J^{(t)} \leq \varepsilon$$

时，可认为本次迭代对代价函数的改善已经很小，并据此判断梯度下降已经收敛。吴恩达老师以 $\varepsilon = 10^{-3}$ 为例，但该数值不是固定标准，需要根据代价函数的尺度和具体任务选择。

实际应用中， ε 往往不容易设定，因此先观察学习曲线通常是更直观的检查方式；需要自动停止训练时，再配合收敛阈值使用。

1.3.3 学习率的选择

学习曲线异常时如何排查

- 若 $J^{(t)}$ 随迭代**持续上升**，通常表示学习率 α 过大，或者代价函数、梯度及参数更新的实现存在错误。
- 若曲线明显上下震荡，梯度下降可能在最小值两侧反复跨越。应尝试减小 α ，并检查各个特征是否已经缩放到相近范围。
- 若 $J^{(t)}$ 始终下降但速度很慢，可以适当增大 α ，同时通过特征缩放改善收敛速度。
- 只有当代价函数正常下降并逐渐变平时，才能将“变化量很小”解释为收敛；代价上升不能被自动停止条件误判为收敛。

1.3.4 特征工程

什么是特征工程

特征工程 (Feature Engineering) 是利用对问题的理解，将已有特征进行选择、组合或变换，从而构造出更能表达数据规律的新特征。合适的新特征可以让较简单的模型表示原本难以拟合的关系。

特征工程改变的是输入 $\mathbf{x}$ 的表示方式，而线性回归模型对参数 $\boldsymbol{\theta}$ 仍然保持线性，因此仍可使用相同的代价函数和梯度下降算法训练。

房价预测中的组合特征

假设房屋的临街宽度为 $x_1 = \text{frontage}$ ，纵向深度为 $x_2 = \text{depth}$ 。只使用原始特征时，模型为

$$h_{\theta}(\mathbf{x}) = \theta_0 + \theta_1 x_1 + \theta_2 x_2.$$

根据房价与占地面积相关的领域知识，可以构造新特征

$$x_3 = x_1 x_2 = \text{frontage} \times \text{depth} = \text{area},$$

并将模型扩展为

$$h_{\theta}(\mathbf{x}) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3.$$

乘积特征 $x_1 x_2$ 表达了两个原始特征之间的交互关系，也使模型能够直接利用“面积”这一更有意义的概念。

构造特征的原则

新特征应当有明确的实际意义或能够表达观察到的数据形状，例如乘积、比值、平方项或平方根等。特征并非越多越好，应通过训练效果和验证集表现判断新特征是否真正有用。

1.3.5 多项式回归

多项式回归

当数据呈现明显的曲线趋势时，一条直线可能无法很好地拟合数据。可以由原始特征 x 构造

$$x_1 = x, \quad x_2 = x^2, \quad x_3 = x^3,$$

再使用线性回归得到三次多项式模型

$$h_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3.$$

模型虽然对输入 x 是非线性的，但对参数 $\theta_0, \theta_1, \theta_2, \theta_3$ 仍然是线性的，所以仍属于线性回归，并可沿用原来的训练方法。

选择合适的特征变换

不同的特征变换可以产生不同形状的拟合曲线，例如

$$\text{二次: } h_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2, \quad \text{平方根: } h_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 \sqrt{x}.$$

应先观察数据的整体趋势，再选择二次项、三次项、平方根或其他有意义的变换，并使用验证集比较不同模型，而不是只凭训练误差决定模型形式。

多项式回归的注意事项

- 幂次会迅速放大特征尺度。例如 x 、 x^2 和 x^3 的取值范围可能相差很多，因此使用梯度下降前**必须对各个多项式特征进行缩放**。
- 多项式次数过低可能无法表达数据规律；次数过高则可能跟随训练数据中的噪声，导致过拟合。
- 高次多项式在训练数据范围之外可能产生不合理的快速增长或下降，因此需要谨慎解释外推结果。