

Study Notes Series

2026 Spring

吴恩达机器学习笔记 (7)

课程：机器学习 作者：C++ 与草稿纸

本节摘要

本周介绍支持向量机 (SVM)：用带间隔的优化目标寻找稳健的分类边界，理解大间隔分类的几何直觉，并使用核函数构造非线性分类器。重点是目标函数、参数 C 、核参数和实际选型。

1 支持向量机的优化目标

从逻辑回归到 SVM

逻辑回归的单样本损失可以看作两段惩罚函数。SVM 用近似折线损失替代对数损失：正类希望 $\theta^T x \geq 1$ ，负类希望 $\theta^T x \leq -1$ 。设 $y \in \{-1, 1\}$ ，则约束可写作

$$y \theta^T x \geq 1.$$

硬间隔与软间隔目标

线性 SVM 的简化目标是

$$\underset{\theta}{\text{minimize}} \quad \frac{1}{2} \sum_{j=1}^n \theta_j^2 + C \sum_{i=1}^m \text{cost}_1(\theta^T x^{(i)}, y^{(i)}),$$

其中 cost_1 和 cost_0 分别对应正类和负类的折线损失。第一项倾向于让参数范数小，第二项惩罚分类错误或落入间隔内的样本。实际实现通常使用凸二次规划求解，而不是手写梯度下降。

2 大间隔分类的直观理解

几何间隔

分类边界由 $\theta^T x = 0$ 给出。参数向量 θ 垂直于边界，点到边界的距离与 $|\theta^T x|/\|\theta\|$ 成正比。SVM 不仅要求分类正确，还希望正负样本离边界有尽可能大的安全间隔。

为什么间隔更稳健

若存在多个能把训练样本分开的直线，靠近样本的边界对噪声和新样本更敏感；大间隔边界尽量远离两侧样本，通常具有更好的泛化能力。落在间隔边界附近、决定最终分界的样本称为支持向量。

C 的作用

C 是误分类惩罚的权重： C 很大时更强调训练集拟合，间隔可能变窄并提高方差； C 较小时允许少量训练错误，间隔更宽，通常更抗噪声。实际应使用交叉验证选择 C 。

3 核函数与非线性边界

特征映射

对输入 x 构造一组相似度特征 $f_1(x), \dots, f_m(x)$ ，再在这些新特征上训练线性 SVM，就可以得到原始空间中的非线性边界。核函数直接计算样本相似度，避免显式构造高维特征。

高斯核

高斯核（RBF kernel）常写为

$$K(x, l) = \exp\left(-\frac{\|x - l\|^2}{2\sigma^2}\right).$$

当 x 接近地标 l 时，核值接近 1；距离较远时接近 0。 σ 控制相似度衰减速度： σ 小会形成局部、复杂的边界， σ 大则边界更平滑。

核函数使用条件

- 特征尺度差异很大时，距离会被大尺度特征主导，应先进行特征缩放；
- 不是所有相似度都能作为合法核函数，常见实现应使用经过验证的核；
- C 和 σ 都是超参数，应在交叉验证集上联合选择；
- 线性核在特征已经足够多或样本极大时可能更快，不必默认使用高斯核。

4 如何使用 SVM

模型选择建议

样本数 m 很大而特征数 n 较小，可考虑线性 SVM； m 中等时可使用高斯核； n 和 m 都很大时，线性模型或近似核方法通常更实际。神经网络也能得到类似的非线性分类能力，但训练和部署成本不同。

多类别 SVM

多类别任务可以训练多个一对多分类器，选择决策函数值最大的类别；也可以使用库提供的多类策略。预测分数不一定是校准概率，需要概率解释时应额外进行校准。

5 本周知识脉络

大间隔与核技巧

SVM 以参数范数和分类损失共同定义优化目标；几何上寻找离样本更远的边界；核函数把相似度变成可学习的高维表示； C 控制误差惩罚， σ 控制高斯核的局部程度。数据缩放、交叉验证和计算规模决定最终选型。