

Study Notes Series

2026 Spring

吴恩达机器学习笔记 (6)

课程：机器学习 作者：C++ 与草稿纸

本节摘要

本周强调机器学习项目中的诊断与决策：先用训练集、交叉验证集和测试集评估模型，再根据偏差、方差和学习曲线决定下一步。随后讨论误差分析、类别不平衡、查准率与查全率，以及数据质量对性能的影响。

1 决定下一步做什么

常见改进方向

当模型效果不理想时，可以增加训练数据、减少或增加特征、增加多项式项、减小或增大正则化参数 λ ，或更换模型。选择哪条路取决于误差来自高偏差还是高方差，而不能只凭直觉修改。

训练集、交叉验证集与测试集

把数据划分为训练集 (train)、交叉验证集 (cross-validation/dev) 和测试集 (test)：

$$J_{\text{train}} = \frac{1}{m_{\text{train}}} \sum L(h_{\theta}(x), y), \quad J_{\text{cv}} = \frac{1}{m_{\text{cv}}} \sum L(h_{\theta}(x), y).$$

训练集用于拟合参数，交叉验证集用于选择模型和超参数，测试集只用于最后一次无偏评估。常见划分可以是 60%/20%/20%，数据量较大时也可采用 98%/1%/1%。

2 评估假设与模型选择

交叉验证选择模型

对不同模型复杂度或不同 λ 分别训练，选择交叉验证误差最小的模型：

$$d^* = \arg \min_d J_{cv}(\theta^{(d)}).$$

最后只在测试集上报告选定模型的泛化误差，避免把测试集信息泄露到模型选择过程。

偏差与方差诊断

训练误差和交叉验证误差的相对大小有助于诊断：

- 训练误差和交叉验证误差都高且相近：通常是高偏差，模型过于简单；
- 训练误差低、交叉验证误差明显高：通常是高方差，模型过拟合；
- 两者都低且差距小：模型通常处于较好的平衡状态。

不同任务的可接受误差还应与人类水平或基线模型比较。

3 学习曲线与正则化

学习曲线

逐渐增加训练样本量，分别记录训练误差和交叉验证误差，可以得到学习曲线。高偏差模型通常两条曲线很快靠近且都较高，继续增加数据帮助有限；高方差模型的训练误差低、验证误差高，增加数据往往有明显帮助。

正则化与偏差方差

对线性回归、逻辑回归或神经网络，改变 λ 后比较 J_{train} 和 J_{cv} ，可以选择合适的正则化强度。应在交叉验证集上选择 λ ，而不是用测试集反复试验。

不要只看训练误差

训练误差低并不说明模型能泛化；加入特征、提高多项式次数或减少 λ 可能让训练误差下降，却让验证误差上升。模型选择必须同时观察验证表现和误差差距。

4 机器学习系统的设计

4.1 先做什么

先建立可测量的基线

先明确目标、收集代表性验证数据，训练一个简单可运行的基线，再用验证误差和错误样本指导改进。优先做能带来最大预期收益的实验，而不是一次改动多个模块。

4.2 误差分析

误差分析

对验证集中的错误样本进行人工检查，统计错误类型和数量。例如垃圾邮件分类可以检查促销、钓鱼、拼写错误等类别。若某类错误占比很高，应优先收集或设计能处理该类错误的数据和特征。

4.3 类别不平衡与度量

查准率、查全率与 F_1

设 TP、FP、FN、TN 分别为真正例、假正例、假负例和真负例：

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}.$$

查准率衡量预测为正的样本有多少确实为正，查全率衡量所有正样本有多少被找出。二者的调和平均为

$$F_1 = \frac{2PR}{P + R}.$$

类别极不平衡时，单看准确率可能产生误导，应报告这些度量和混淆矩阵。

阈值权衡

提高分类阈值通常会提高查准率、降低查全率；降低阈值则相反。应根据误报和漏报的业务代价选择阈值，而不是默认 0.5 永远最优。

4.4 数据的重要性

高质量数据的条件

数据应覆盖真实使用场景，标签定义一致，输入与部署时可获得的信息一致，并尽量减少系统性的测量偏差。增加数据前，应先确认当前瓶颈确实是高方差或数据覆盖不足。

5 本周知识脉络

用诊断驱动工程决策

可靠的流程是：建立基线，划分训练/交叉验证/测试集；同时比较训练误差和验证误差；用学习曲线与误差分析判断偏差、方差和主要错误类型；再决定收集数据、修改特征、调整正则化还是改变模型；最后用一次测试集评估报告结果。