

Study Notes Series

2026 Spring

吴恩达机器学习笔记 (10)

课程：机器学习 作者：C++ 与草稿纸

本节摘要

本周讨论大规模机器学习和图片文字识别。重点是随机梯度下降、小批量梯度下降、在线学习以及分布式数据处理，并用图片文字识别说明如何设计端到端的机器学习管道、滑动窗口和数据上限分析。

1 大规模数据集的学习

先判断是否真的需要更多数据

大数据不是自动带来好效果。应先画学习曲线，判断模型是高偏差还是高方差；若验证误差随数据增加仍然很高，增加数据可能无效，需要修改特征或模型。只有在高方差场景下，扩大数据集通常才有明显收益。

2 随机梯度下降

批量与随机梯度下降

批量梯度下降每次使用全部 m 个样本：

$$\theta \leftarrow \theta - \alpha \frac{1}{m} \sum_{i=1}^m \nabla L_i(\theta).$$

随机梯度下降（SGD）逐个样本更新：

$$\theta \leftarrow \theta - \alpha \nabla L_i(\theta), \quad i = 1, \dots, m.$$

SGD 每次更新便宜、可快速处理海量数据，但目标函数会有噪声，通常在最优点附近波动。

小批量梯度下降

将连续 b 个样本组成一个小批量：

$$\theta \leftarrow \theta - \alpha \frac{1}{b} \sum_{i=t}^{t+b-1} \nabla L_i(\theta).$$

批量大小 b 常取 32、64、128 等，既能利用向量化和 GPU，又比全批量更新更快。每个 epoch 前可以随机打乱样本，减少固定顺序带来的偏差。

收敛与学习率

观察每个 epoch 的平均代价而不是单个样本损失。若平均代价总体下降但有小幅波动，可能是 SGD 的正常噪声；若持续上升，检查学习率是否过大、特征是否缩放以及实现是否有错误。也可以逐渐衰减学习率，但衰减策略必须在验证集上评估。

3 在线学习

在线学习

在线学习不断接收一个新样本 (x, y) ，立刻用它更新参数，然后丢弃或存档该样本。它适合广告点击率、搜索排序或物流需求等数据分布随时间变化的场景。

$$\theta \leftarrow \theta - \alpha \nabla L(\theta; x, y).$$

在线学习的风险

在线数据可能包含垃圾样本、反馈回路或分布漂移。需要监测指标、保留离线验证集、限制异常更新，并定期用新旧数据重新评估模型。在线学习不是跳过数据清洗和模型验证。

4 映射化简与数据并行

MapReduce 思路

把大数据分到多个机器上：Map 阶段在各节点计算局部损失和梯度，Reduce 阶段把局部结果求和或平均，再执行一次参数更新。只要局部梯度的组合与全数据梯度等价，就可以在不把所有数据放到一台机器上的情况下训练模型。

分布式训练注意事项

通信成本、节点故障、数据分片是否均衡和参数同步方式都会影响速度。异步更新吞吐较高但梯度可能过期，同步更新更稳定但要等待最慢节点。工程上需根据模型规模和网络条件选择方案。

5 应用实例：图片文字识别

5.1 问题描述和流程图

端到端管道

图片文字识别通常拆为文字区域检测、字符分割或序列识别、字符分类和结果拼接等阶段。每个模块都有输入、输出和可测量指标，错误可能在任意阶段累积，因此不能只看最终准确率。

5.2 滑动窗口

滑动窗口检测

使用固定大小的窗口从左到右、从上到下扫描图像，对每个窗口预测“是否包含文字”。为了检测不同大小的文字，可以使用多个窗口尺寸或对图像做多尺度缩放。检测结果通常需要后处理合并重叠区域。

5.3 获取数据与上限分析

数据和人工上限

人工检查不同阶段的错误，估计每个模块距离理想性能还有多少空间。如果某一模块的上限已经接近最终指标，而另一模块仍有较大差距，应优先改进后者。合成数据、迁移学习和主动收集困难样本可以提高数据利用效率。

误差预算

若文字检测准确率为 95%、字符识别准确率为 96%，最终正确率不会简单等于两者之和，而会受到错误传播影响。应分别测量“检测正确但识别错误”“检测遗漏”等类型，再决定增加标注、修改窗口还是更换分类器。

6 课程总结

从模型到系统

本课程的主线是：线性回归和逻辑回归建立基本监督学习工具；神经网络和 SVM 扩展非线性表示；聚类、PCA 和异常检测处理无监督问题；推荐系统学习用户偏好；大规模学习则关注数据、计算和部署。实际项目中，算法只是系统的一部分，数据质量、验证设计、误差分析和工程约束同样决定最终效果。